Отчет о частичном воспроизведении метода SeedLM

Цель.

Проверить метод сжатия весов SeedLM через seed генератора LFSR и набор квантованных коэффициентов, оценить ошибку восстановления и фактический размер упакованных данных.

Методика.

Реализованы генерация LFSR, построение нормализованной матрицы U(s), поиск коэффициентов методом наименьших квадратов, 4-битное квантование коэффициентов с общим показателем степени и выбор seed с минимальной ошибкой.

Пример для K = 3 сверялся с рисунком 3 статьи: при seed = 4 и w = (0, 1, 0, 0) получена SSE = 0,4375.

Основной опыт выполнен для 1536 синтетических весов из N(0, 1) с фиксированным генератором случайных чисел (42). Параметры взяты из таблицы 1 статьи: 4 бита - K = 16, C = 8, P = 3. 3 бита - K = 16, C = 12, P = 4. Сравнивались 16, 64, 256 и 1024 кандидата seed; метрика - NMSE.

Результаты.

При 4 битах NMSE составила 0,30374; 0,20814; 0,14689; 0,10265 для 16, 64, 256 и 1024 seed соответственно.

При 3 битах - 0,43562; 0,31690; 0,24349; 0,18725. С расширением поиска ошибка в обоих режимах уменьшалась. В отдельном контрольном эксперименте с одним блоком полный перебор 65535 seed снизил SSE с 0,53521 до 0,24618 (на 54,0%) для 4 бит и с 1,68334 до 0,63919 (на 62,0%) для 3 бит.

Степень сжатия.

Для 1536 весов объем FP16 равен 3072 байтам. Плотно упакованные представления SeedLM заняли 768 байт (4 бита на вес - сжатие в 4 раза) и 576 байт (3 бита - в 5,33 раза). Эти значения характеризуют только сохраненные веса и не включают накладные расходы целой модели.

Вывод.

Seed и квантованные коэффициенты позволяют уменьшить объем представления весов, а расширение поиска seed снижает ошибку их восстановления. При этом 4-битная конфигурация на выбранных данных дала меньшую NMSE, чем 3-битная.

Статья: https://arxiv.org/pdf/2410.10714